Régression Logistique Multinomiale :
Prédiction de la Désertion Scolaire

Université Sidi Mohamed Ben Abdellah De Fès
Faculté des Sciences Dhar El Mahrez

Web Intelligence Et Sciences De Données (WISD)

14 février 2026

Plan de la présentation

1. Introduction
2. Régression Logistique Multinomiale
3. Présentation des données
4. Modélisation et résultats
5. Code source R
6. Discussion et recommandations
7. Conclusion

Contexte du projet

Constat

- 30% des étudiants abandonnent en licence
- Coût social : 5 milliards d'€/an
- Impact psychologique majeur

Enjeux

- Équité des chances
- Optimisation des ressources
- Insertion professionnelle

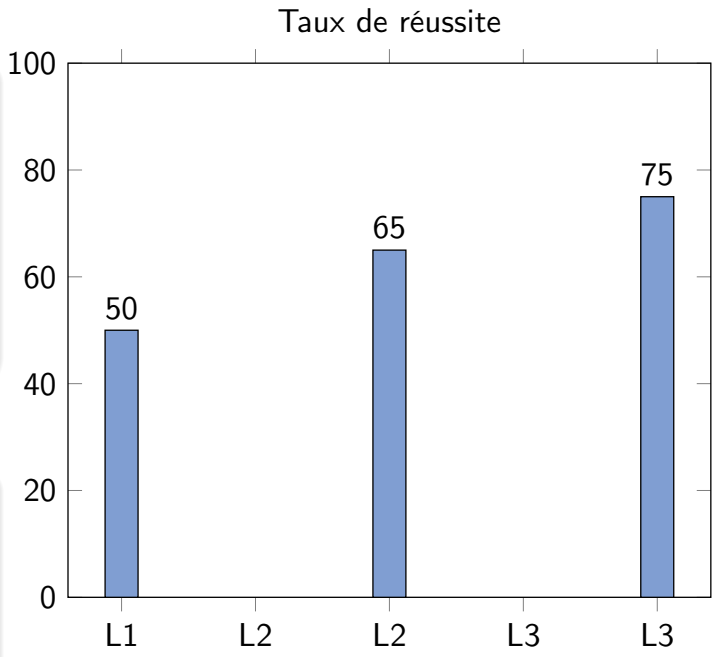

Objectifs du projet

Objectifs

1. Identifier les facteurs clés de la désertion scolaire
2. Modéliser la probabilité d'abandon
3. Fournir des outils d'aide à la décision

Question centrale

Comment modéliser et prédire efficacement le risque de désertion scolaire ?

Introduction à la RLM

Définition

Extension de la régression logistique binaire pour les variables à plus de 2 modalités.

Binaire (2 classes)

↓

Multinomiale (3 classes)

Application : Diplômé, Inscrit, Déserté

Formulation mathématique

Modèle logit :

$$\ln\left(\frac{P(Y=j)}{P(Y=1)}\right) = \beta_{j0} + \beta_{j1}X_1 + \ldots + \beta_{jp}X_p$$

Probabilités :

$$P(Y=j) = \frac{\exp(\beta_j X)}{1 + \sum_{k=2}^{3} \exp(\beta_k X)}$$

avec $j = 2$ (Inscrit), $j = 3$ (Déserté), référence = Diplômé

Relative Risk Ratios (RRR)

Définition

$RRR = \exp(\beta_{jm})$

Valeur	Interprétation
$RRR = 1$	Pas d'effet
$RRR > 1$	Facteur de risque
$RRR < 1$	Facteur protecteur

Exemple : $RRR = 1.5 \Rightarrow +50\%$ de risque

Estimation des paramètres

Maximum de vraisemblance

$$L(\beta) = \prod_{i=1}^{n} \prod_{j=1}^{3} P(Y_i = j | X_i)^{\mathbb{1}(Y_i = j)}$$

Algorithme de Newton-Raphson :

$$\beta^{(t+1)} = \beta^{(t)} - H^{-1} \nabla \ell$$

Hypothèses du modèle

- Indépendance des observations
- Absence de multicolinéarité
- Linéarité des logits
- Hypothèse IIA

Test de Hausman : vérification de l'hypothèse IIA

Structure du jeu de données

- **Source :** Enquête nationale (2020-2024)
- **Taille :** 4 424 étudiants
- **Variables :** 36 prédicteurs

Statut	**n**	**%**
Diplômé	2209	49.9%
Inscrit	1422	32.2%
Déserté	793	17.9%

Variables académiques

- Notes S1
- Notes S2
- Assiduité
- Redoublement
- Crédits ECTS
- Mention bac
- Type bac
- Rattrapage

Variables socio-démographiques

- Âge
- Genre
- Nationalité
- CSP parents
- Logement
- Distance
- Transport
- Situation familiale

Variables économiques

- Statut boursier
- Montant bourse
- Emploi étudiant
- Heures travaillées
- Revenus fiscaux
- Retard paiement
- Prêt étudiant
- Aide famille

Analyse univariée - Notes

Statut	Moyenne	ET	Médiane
Diplômé	13.2	2.1	13.5
Inscrit	11.8	2.8	12.0
Déserté	9.4	3.2	9.8

ANOVA : $F = 456.7$, $p < 0.001$

Analyse univariée - Assiduité

Statut	Moyenne	ET	Médiane
Diplômé	92.5%	5.2	94.0%
Inscrit	81.3%	12.4	85.0%
Déserté	65.8%	18.7	70.0%

ANOVA : $F = 823.4$, $p < 0.001$

Analyse univariée - Facteurs économiques

Bourse

- Boursiers : 12% désertion
- Non-boursiers : 24% désertion

Emploi étudiant :

- 0h : 14%
- 1-10h : 18%
- 11-20h : 25%
- >20h : 35%

Paiement

- À jour : 5% désertion
- Retard : 35% désertion
- $OR = 10.2$

Analyse univariée - Démographie

Âge

- Diplômé : 18.5 ans
- Inscrit : 19.2 ans
- Déserté : 20.1 ans

Logement :

- CROUS : 15% désertion
- Privé : 22% désertion
- Famille : 17% désertion

Genre

- Femmes : 15% désertion
- Hommes : 21% désertion

Matrice de corrélation

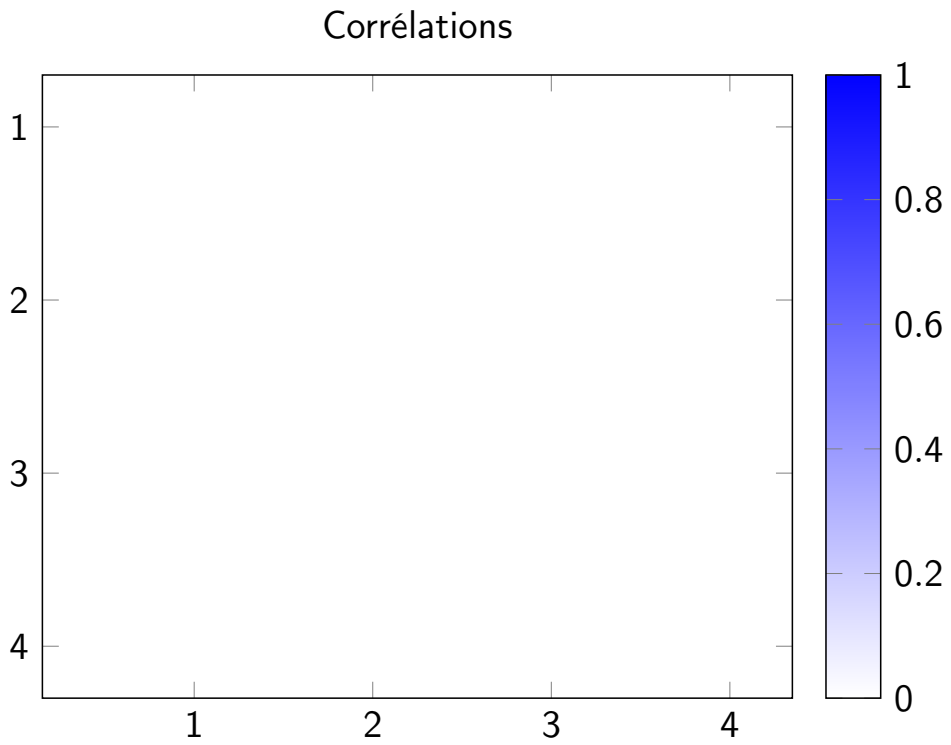

- Notes S1 - Notes S2 : $r = 0.78$
- Notes - Désertion : $r = -0.45$

Sélection des variables

Variable	**p-value**
Notes S1	< 0.001
Notes S2	< 0.001
Âge	< 0.001
Genre	0.009
Boursier	< 0.001
Paiement retard	< 0.001
Emploi étudiant	< 0.001
Assiduité	< 0.001
Logement	0.019

Coefficients - Déserté vs Diplômé

Variable	β	SE	p-value
Intercept	2.145	0.234	< 0.001
Notes S1	-0.156	0.018	< 0.001
Notes S2	-0.189	0.021	< 0.001
Âge	0.087	0.023	< 0.001
Genre (H)	0.234	0.089	0.009
Boursier	-0.567	0.112	< 0.001
Paiement retard	0.892	0.145	< 0.001
Emploi étudiant	0.445	0.098	< 0.001
Assiduité	-0.023	0.004	< 0.001

Coefficients - Inscrit vs Diplômé

Variable	β	SE	p-value
Intercept	0.845	0.178	< 0.001
Notes S1	-0.078	0.012	< 0.001
Notes S2	-0.092	0.015	< 0.001
Âge	0.023	0.018	0.201
Genre (H)	0.089	0.067	0.184
Boursier	-0.234	0.089	0.009
Paiement retard	0.445	0.123	< 0.001
Emploi étudiant	0.167	0.078	0.032
Assiduité	-0.012	0.003	< 0.001

Relative Risk Ratios - Déserté

Variable	**RRR**
Notes S1	0.856
Notes S2	0.828
Âge	1.091
Genre masculin	1.264
Boursier	0.567
Paiement retard	2.440
Emploi étudiant	1.561
Assiduité	0.977

Relative Risk Ratios - Inscrit

Variable	**RRR**
Notes S1	0.925
Notes S2	0.912
Âge	1.023
Genre masculin	1.093
Boursier	0.791
Paiement retard	1.561
Emploi étudiant	1.182
Assiduité	0.988

Interprétation des RRR

Facteurs de risque

- Paiement retard : +144%
- Emploi étudiant : +56%
- Genre masculin : +26%
- Âge : +9%/an

Facteurs protecteurs

- Bourse : -43%
- Notes S2 : -17%/point
- Notes S1 : -14%/point
- Assiduité : -2%/point

Matrice de confusion

	Prédit		
Observé	Diplômé	Inscrit	Déserté
Diplômé	**389**	47	9
Inscrit	58	**215**	32
Déserté	12	28	**125**

Accuracy globale : 79.7%

Métriques par classe

Métrique	**Diplômé**	**Inscrit**	**Déserté**
Sensibilité	87.4%	70.5%	75.8%
Précision	84.7%	74.1%	75.3%
F1-score	0.860	0.723	0.755

Métriques globales

- **Accuracy :** 79.7%
- **Kappa :** 0.68
- **AUC macro :** 0.87
- **Log-loss :** 0.48

Validation croisée 10-fold

Accuracy moyenne : 78.5% $\pm$ 2.3%

Courbes ROC

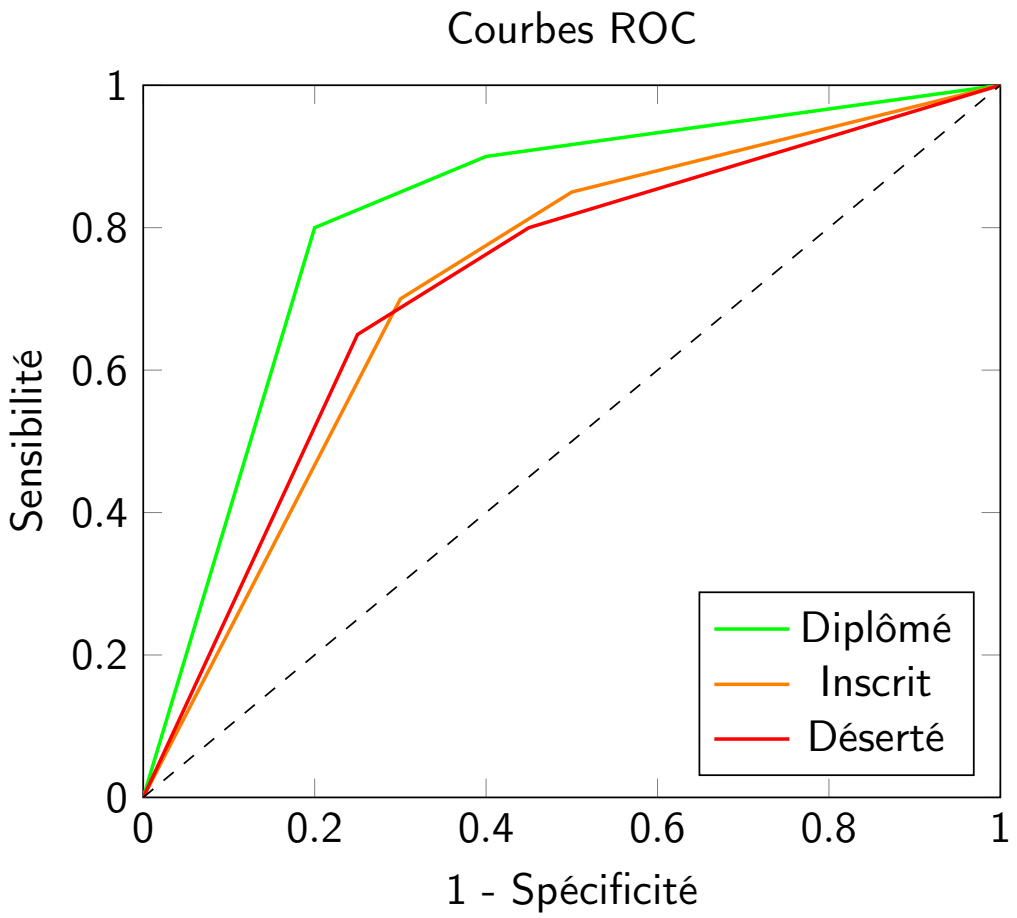
Courbes ROC
Sensibilité
1 - Spécificité
0
0.2
0.4
0.6
0.8
1
Diplômé
Inscrit
Déserté

Code R - Préparation

```r
library(nnet)
library(caret)

# Pr paration
data$Target <- relevel(factor(data$Target), ref="Diplome")

# Division train/test
set.seed(123)
trainIndex <- createDataPartition(data$Target, p=0.8, list=FALSE)
train <- data[trainIndex, ]
test <- data[-trainIndex, ]
```

Code R - Modèle

```
# Mod le multinomial
model <- multinom(Target ~ Notes_S1 + Notes_S2 + Age +
                  Genre + Boursier + Paiement_retard +
                  Emploi_etudiant + Assiduite + Logement,
                  data=train, trace=FALSE)

# Coefficients
summary(model)
exp(coef(model))  # RRR

# Pr dictions
pred <- predict(model, newdata=test, type="class")
proba <- predict(model, newdata=test, type="probs")
```

Code R - Évaluation

```
# Matrice de confusion
confusionMatrix(pred, test$Target)

# Courbes ROC
library(pROC)
multiclass.roc(test$Target, proba)

# Validation crois e
ctrl <- trainControl(method="cv", number=10)
cv_model <- train(Target ~ ., data=train,
                  method="multinom", trControl=ctrl)
```

Synthèse des résultats

Facteurs de risque

1. Paiement retard (x2.44)
2. Emploi étudiant (+56%)
3. Âge élevé (+9%/an)

Facteurs protecteurs

1. Bourse (-43%)
2. Notes élevées (-17%/point)
3. Assiduité (-2%/point)

Forces du modèle

- Performance : 79.7% d'accuracy
- Robustesse : validation croisée stable
- Interprétabilité : RRR clairs
- Prédictivité précoce

Limites

Limites

- Corrélation $\neq$ causalité
- Variables omises (motivation)
- Non-linéarités possibles
- Échantillon spécifique

Recommandations - Niveau 1

1. **Système d'alerte précoce**
   - Seuils : notes < 10, retard paiement
   - Notification automatique
2. **Interventions académiques**
   - Tutorat pour notes faibles
   - Ateliers méthodologie

Recommandations - Niveau 2

3. **Soutien financier**
   - Fonds d'urgence
   - Échelonnement paiements
   - Emplois campus (max 10h)
4. **Accompagnement**
   - Cellule psychologique
   - Mentorat par pairs

Plan d'action

Action	Impact
Tutorat	-30% risque
Fonds urgence	-50% risque
Flexibilité emploi	-25% risque
Ateliers budget	-15% risque
Mentorat	-20% risque

ROI estimé : 295%

Contributions

- **Modèle validé** : 79.7% accuracy
- **Facteurs clés** : paiement, bourse, notes
- **Outil opérationnel** : code R, seuils d'alerte

Résultats clés

Top 3 facteurs de risque

1. Paiement retard (RRR = 2.44)
2. Emploi étudiant (RRR = 1.56)
3. Genre masculin (RRR = 1.26)

Top 3 facteurs protecteurs

1. Bourse (RRR = 0.57)
2. Notes S2 (RRR = 0.83)
3. Assiduité (RRR = 0.98)

Implications

Pour les universités

Système d'alerte automatisé

Pour les politiques

Renforcement des bourses

Pour les étudiants

Information personnalisée

Références

- Agresti, A. (2012). Categorical Data Analysis.
- Hosmer, D.W. (2013). Applied Logistic Regression.
- MESRI (2023). État de l'Enseignement supérieur.